



東北大學 国家示范性软件学院
SOFTWARE COLLEGE OF NORTHEASTERN UNIVERSITY



Python for Data Analysis —— PART II Improved

1



Chapter 1: Python Data Analysis Overview

Contents



Learning Path for Python Data Analysis


1. Why Python for Data Analysis?

- For many people, the Python programming language has strong appeal(吸引力).
- In the last 10 years, Python has gone from a bleeding-edge(前沿) or “at your own risk” (风险自负) scientific computing language to one of the most important languages for **data science, machine learning**, and **general software development** in academia and industry.
- Part of Python’ s success in scientific computing is the ease of integrating C, C++, and FORTRAN code(for doing linear algebra, optimization(优选) , integration(积分), fast Fourier transforms(快速傅里叶变换), and other such algorithms).




Learning Path for Python Data Analysis

2. Learning Path




Learning Path for Python Data Analysis

① Using Python to read and write data




Learning Path for Python Data Analysis

② Using Python to process data



Learning Path for Python Data Analysis

③ Analytical Modeling with Python



Learning Path for Python Data Analysis

Python中有关数据分析/数据挖掘相关的库

- numpy: 数组支撑, 可用来做高维度矩阵计算
- Scipy: 提供矩阵支持, 以及矩阵相关的数值计算和科学计算
- pandas: 强大灵活的数据分析和探索工具
- matplotlib: 强大的数据可视化工具、作图
- scikit-learn: 支持回归、分类、聚类等强大的机器学习与数据挖掘库



Learning Path for Python Data Analysis

1. NumPy(Numerical Python)—— Python 科学计算的基础包

- 快速高效的多维数组对象 ndarray。
- 对数组执行元素级的计算以及直接对数组执行数学运算的函数。
- 读写硬盘上基于数组的数据集的工具。
- 线性代数运算、傅里叶变换，以及随机数生成的功能。
- 将 C、C++、Fortran 代码集成到 Python 的工具。



Learning Path for Python Data Analysis

2. SciPy——专门解决科学计算中各种标准问题域的模块的集合

SciPy 主要包含了 8 个模块，不同的子模块有不同的应用，如插值、积分、优化、图像处理和特殊函数等。

- `scipy.integrate` 数值积分例程和微分方程求解器
- `scipy.linalg` 扩展了由 `numpy.linalg` 提供的线性代数例程和矩阵分解功能
- `scipy.optimize` 函数优化器（最小化器）以及根查找算法
- `scipy.signal` 信号处理工具
- `scipy.sparse` 稀疏矩阵和稀疏线性系统求解器
- `scipy.special` SPECFUN（这是一个实现了许多常用数学函数的 Fortran 库）的包装器
- `scipy.stats` 检验连续和离散概率分布、各种统计检验方法，以及更好的描述统计法
- `scipy.weave` 利用内联 C++ 代码加速数组计算的工具

10



Learning Path for Python Data Analysis

3. Pandas——数据分析核心库

pandas是Python的数据分析核心库，最初被作为金融数据分析工具而开发出来。

- 为时间序列分析提供了很好的支持。
- 提供了一系列能够快速、便捷地处理结构化数据的数据结构和函数。
- 兼具 Numpy高性能的数组计算功能以及电子表格和关系型数据库(如 SQL)灵活的数据处理功能。
- 复杂精细的索引功能，以便便捷地完成重塑、切片和切块、聚合及选取数据子集等操作。



Learning Path for Python Data Analysis

4. Matplotlib——绘制数据图表的 Python 库

Matplotlib是最流行的用于绘制数据图表的 Python库，是 Python的2D绘图库

- 非常适合创建出版物上用的图表。
- 操作比较容易，只需几行代码即可生成柱状图、功率谱图、条形图、错误图和散点图等图形。
- 提供了pylab的模块，其中包括了NumPy和pyplot中许多常用的函数，方便用户快速进行计算和绘图。
- Matplotlib与 IPython结合得很好，交互式的数据绘图环境，绘制的图表也是交互式的。

12



Learning Path for Python Data Analysis

5. scikit-learn——简单有效的数据挖掘和数据分析工具

- 简单有效，可以供用户在各种环境下重复使用。
- scikit - learn建立在 NumPy、Scipy和 Matplotlib基础之上，封装了一些常用的算法方法。
- 基本模块主要有数据预处理、模型选择、分类、聚类、数据降维和回归 6 个。
- 在数据量不大的情况下，scikit-learn可以解决大部分问题。
- 对算法不精通的用户在执行建模任务时，并不需要自行编写所有的算法，只需要简单的调用scikit - learn库里的模块就可以。



Learning Path for Python Data Analysis


	R	Python	MATLAB
语言学习 难易程度	入门难度低	入门难度一般	入门难度一般
使用场景	数据分析, 数据挖掘, 机器学习, 数据可视化等。	数据分析, 机器学习, 矩阵运算, 科学数据可视化, 数字图像处理, web应用, 网络爬虫, 系统运维等。	矩阵计算, 数值分析, 科学数据可视化, 机器学习, 符号计算, 数字图像处理, 数字信号处理, 仿真模拟等。
第三方支持	拥有大量的Packages, 能够调用C, C++, Fortran, Java等其他程序语言。	拥有大量的第三方库, 能够简便地调用C, C++, Fortran, Java等其他程序语言。	拥有大量专业的工具箱, 在新版本中加入了对C, C++, Java的支持。
流行领域	工业界 $\approx$ 学术界	工业界 > 学术界	工业界 $\leq$ 学术界
软件成本	开源免费	开源免费	商业收费

14



Learning Path for Python Data Analysis

3. Typical data analysis process



Chapter 1: Python Data Analysis Overview

Contents



Data Analysis Application Scenario(应用场景)

1. 客户分析

主要是客户的基本数据信息进行商业行为分析

- 首先**界定目标客户**，根据客户的需求，目标客户的性质，所处行业的特征以及客户的经济状况等基本信息使用统计分析方法和预测验证法，分析目标客户，提高销售效率。
- 其次**了解客户采购过程**，根据客户采购类型、采购性质进行分类分析制定不同的营销策略。
- 最后还可以根据已有的客户特征，进行**客户特征分析、客户忠诚分析、客户注意力分析、客户营销分析和客户收益分析**。



Data Analysis Application Scenario(应用场景)

2. 营销分析

- **产品分析**主要是竞争产品分析，通过对竞争产品的分析制定自身产品策略。
- **价格分析**又可以分为成本分析和售价分析，成本分析的目的是降低不必要成本，售价分析的目的是制定符合市场的价格。
- **渠道分析**目的是指对产品的销售渠道进行分析，确定最优的渠道配比。
- **广告与促销分析**则能够结合客户分析，实现销量的提升，利润的增加。

大数据，是为**大**营销服务



Data Analysis Application Scenario(应用场景)

3. 社交媒体分析

以不同社交媒体渠道生成的内容为基础，实现不同社交媒体的用户分析，访问分析，互动分析等。同时，还能为情感和舆情监督提供丰富的资料。


- **用户分析** 主要根据用户注册信息，登录平台的时间点和平时发表的内容等用户数据，分析用户个人画像和行为特征。
- **访问分析** 则是通过用户平时访问的内容，分析用户的兴趣爱好，进而分析潜在的商业价值。
- **互动分析** 根据互相关注对象的行为预测该对象未来的某些行为特征。



Data Analysis Application Scenario(应用场景)

4. 网络安全

新型的病毒防御系统可使用数据分析技术，建立潜在攻击识别分析模型，监测大量网络活动数据和相应的访问行为，识别可能进行入侵的可疑模式，做到未雨绸缪。



Data Analysis Application Scenario(应用场景)

5. 设备管理

通过物联网技术能够收集和分析设备上的数据流，包括连续用电、零部件温度、环境湿度和污染物颗粒等无数潜在特征，建立设备管理模型，从而预测设备故障，合理安排预防性的维护，以确保设备正常作业，降低因设备故障带来的安全风险。



Data Analysis Application Scenario(应用场景)

6. 交通物流分析

物流是物品从供应地向接收地的实体流动。通过业务系统和GPS定位系统获得数据，对于客户使用数据构建交通状况预测分析模型，有效预测实时路况、物流状况、车流量、客流量和货物吞吐量，进而提前补货，制定库存管理策略。



22



Data Analysis Application Scenario(应用场景)

7. 欺诈行为检测

身份信息泄露盗用事件逐年增长，随之而来的是欺诈行为和交易的增多。公安机关，各大金融机构，电信部门可利用用户基本信息，用户交易信息，用户通话短信信息等数据，识别可能发生的潜在欺诈交易，做到提前预防未雨绸缪。

